

大语言模型多智能体协作研究的文献计量综述：从知识图谱到垂直场景落地

高俊杰

湖南大学文献计量学课程项目；GitHub 项目：LLM-trends-analysis-main

摘要

大语言模型正在从单模型问答工具演化为能够分解任务、调用工具、协同角色并执行复杂工作流的多智能体系统。本文参考文献计量型 Review 的写法，基于 Lens.org Scholarly Works 构建 2020-2026 年相关文献数据集，经 DOI 与题名去重后保留 522 篇有效记录。研究使用年度发文趋势、作者合作网络、关键词共现、Top 10 高被引文献和共被引网络识别领域发展阶段、研究主体、主题结构和知识基础。结果显示，该领域在 2024-2025 年进入快速扩张期，2025 年发文量达到 344 篇；样本总被引次数为 4,265，h 指数为 31。关键词与代表文献共同表明，LLM 多智能体协作研究已形成科学发现与自驱动实验室、机器人任务规划、软件与自动化工作流、人机协作及医疗等垂直应用主线。本文进一步讨论评价体系不统一、协作过程可解释性不足、真实场景验证有限以及安全治理复杂化等挑战。

关键词：大语言模型；多智能体系统；文献计量学；关键词共现；共被引网络；课程论文

1. Introduction

大语言模型正在从单模型问答工具演化为能够分解任务、调用工具、协同角色并执行复杂工作流的多智能体系统。早期 LLM 应用主要围绕问答、摘要、翻译和代码生成展开；而在工具调用、RAG、函数调用和长上下文推理能力增强后，LLM 开始被组织成能够分工、通信、执行和反思的智能体系统。

与单模型应用相比，多智能体系统强调角色分配、任务拆解、过程监督和结果校验，因此更适合复杂工作流、科学发现、机器人规划、软件工程和医疗辅助等场景。它的研究对象并不是单个模型能力，而是模型、工具、人类监督、任务流程和制度环境共同构成的协作系统。

文献计量型综述的重点不是简单罗列论文，而是先用可复现数据建立领域结构，再围绕图谱结果组织主题解释。本文参考 bibliometric mini review 的写法，将年度趋势、合作网络、关键词共现、高被引论文和共被引网络分别对应到明确的研究问题，形成“问题—证据—解释”的写作链条。

因此，本文主要围绕三个方面展开：第一，基于 Lens.org 构建 2020-2026 年 LLM 多智能体协作文献数据集，并保留从检索式到清洗规则的可复核记录；第二，将核心三图一表与 RQ 明确绑定，使图表成为回答问题的证据；第三，在计量结果基础上归纳该领域的技术主线、落地挑战与未来研究议程。

Research questions

为避免综述问题过宽，本文将研究对象限定为“LLM 与多智能体协作交叉领域的学术文献”。因此，本文不评价所有生成式人工智能研究，也不把所有传统 autonomous agent 文献纳入同一结论，而是通过检索式、字段清洗和阈值设置形成可复核样本。

五个 RQ 之间存在递进关系。增长趋势说明研究活动是否充足，合作网络说明研究主体如何组织，关键词网络说明内容集中在哪里，高被引与共被引分析说明哪些论文支撑知识结构，未来议程则进一步讨论该领域的评价、解释性、真实场景验证和安全治理问题。

RQ	具体研究问题	主要证据
RQ1	2020-2026 年 LLM 多智能体协作研究的发文量如何变化，领域处于什么发展阶段？	Fig. 2; Table 2
RQ2	核心研究主体和合作结构是否已经形成稳定团队与中心化共同体？	Fig. 3; Fig. 9
RQ3	关键词共现揭示了哪些研究热点，这些热点之间形成怎样的技术层次？	Fig. 4; Fig. 5
RQ4	哪些高被引论文构成该领域知识基础，它们如何支撑主题综述？	Table 1; Fig. 6; Fig. 7
RQ5	从计量图谱和代表性论文看，未来研究还存在哪些缺口和挑战？	Fig. 10; Discussion

表 RQ. 研究问题与图表证据的对应关系。该表展示核心图表如何分别支撑发展趋势、合作结构、主题热点、知识基础与未来议程等分析维度。

2. Data and methods

本文数据来自 Lens.org Scholarly Works。检索逻辑采用 Object AND Method：Object 词组包括 Large Language Model*、LLM*、Generative AI、Foundation Model* 和 ChatGPT；Method 词组包括 Multi-agent*、Collaboration、Coordination、Cooperation 和 Multi-agent system*。时间范围为 2020-2026，文献类型为 Article、Review 和 Conference Paper，语言限定为 English。

采用 Object AND Method 的原因在于 LLM 多智能体研究具有跨学科特征。如果只检索“multi-agent system”，容易得到传统多智能体强化学习和机器人系统；如果只检索“large language model”，又会混入大量与协作机制无关的文本生成研究。双组检索可以在召回率和主题相关性之间取得平衡。

原始导出包含 542 条记录。清洗流程优先使用 DOI 去重，再使用标准化题名去重，最终保留 522 篇有效文献。这样做可以处理 DOI 缺失、数据库重复收录、大小写差异和标点差异等问题。最终样本保留率较高，说明检索式具有一定稳定性，但去重仍然是保证分析可信度的必要步骤。

纳入标准包括：文献主题与大语言模型、生成式 AI、基础模型或 ChatGPT 相关；同时涉及 multi-agent、collaboration、coordination、cooperation 或类似协作机制；文献具有可用于去重和分析的题名、年份、作者、DOI 或参考文献字段。排除标准包括：明显无关的传统多智能体研究、非学术材料、重复记录、字段严重缺失且无法定位的记录。

项目使用 Python、pandas、matplotlib、seaborn、NetworkX 与 wordcloud 等开源工具完成数据清洗和可视化。关键词共现以文献关键词为分析单元，同一篇文献内部去重，共现阈值设为 2；作者合作网络以共同署名为边，展示时过滤一次性合作以突出重复合作关系；高被引文献按 Lens.org Citing Works Count 排序取 Top 10。

参数选择经过敏感性检查。关键词阈值为 1 时网络过密，会把偶然共现和低频噪声全部纳入；阈值过高又会遗漏新兴主题。项目的敏感性分析显示，阈值为 2 时保留 233 个节点和 2,511 条边，既能呈现主题联系，又不至于让图谱不可读。作者合作图同理，过滤一次性合作是为了观察稳定关系，而不是否定一次性合作的学术价值。

透明度项目	本文设置
数据库名称	Lens.org Scholarly Works
完整检索式	(Large Language Model* OR LLM* OR Generative AI OR Foundation Model* OR ChatGPT) AND (Multi-agent* OR Collaboration OR Coordination OR Cooperation OR Multi-agent system*)
检索/导出日期	2026-03-26, 精确到日
时间范围	2020-2026, 其中 2026 年为不完整年份
文献类型	Article, Review, Conference Paper
纳入标准	同时涉及 LLM/生成式 AI/基础模型与多智能体、协作、协调或合作机制
排除标准	传统多智能体但与 LLM 无关的文献、重复记录、字段严重缺失且无法定位的记录
去重规则	优先 DOI 去重, 再按标准化题名去重; 542 条原始记录清洗为 522 条
工具版本	Python + pandas + NetworkX + matplotlib/seaborn; 项目依赖记录于 requirements.txt
阈值参数	关键词共现阈值 >=2; 作者合作展示阈值 >=2; 高被引文献取 Top 10

表 M. 方法透明度清单，概括数据来源、检索式、时间范围、筛选规则、工具和主要阈值。

字段	覆盖率	对分析的意义
Title / Year	100%	支持年份趋势、题名去重和时间窗口分析
Abstract	98.28%	支持主题解释和文本语义核对
References	81.99%	可做初步共被引分析，但需要说明字段缺失边界
DOI	99.81%	支持较可靠的文献定位和去重
Open access	73.18%	便于复核，但不等同于全文质量评价

表 3. 数据字段覆盖率与解释边界。 覆盖率用于判断哪些图表结论可以被稳妥解释。




Fig. 1. 文献检索、清洗、计量分析和综述写作流程图。数据源为 Lens.org，时间范围为 2020-2026，分析单元为 scholarly work；该图说明本文的证据链从原始记录进入清洗数据，再进入图表、主题解释和未来议程。

3. Bibliometric results

指标	数值	解释
原始记录	542	Lens.org 初始导出结果
清洗后记录	522	DOI + Title 去重后样本
总被引次数	4,265	领域整体影响力信号
篇均被引	8.17	受大量近年论文影响偏低
被引中位数	1.00	说明新论文占比比较高
高被引论文	20 篇	被引次数大于 50 的论文
零被引论文	236 篇	主要来自 2024-2026 年新论文
h 指数	31	核心影响力较稳定
作者总数	2,564	参与者规模较大
篇均作者数	5.07	体现协作型研究特征

表 2. 核心计量指标汇总。指标来自 `outputs/metrics_summary.txt` 和 M2 阶段分析结果。

核心证据	本文对应图表	RQ	解释作用
核心图1	Fig. 2 年度发文增长与发展阶段图	RQ1	判断领域是否进入快速扩张阶段
核心图2	Fig. 3 作者合作网络图	RQ2	判断研究共同体是否形成稳定合作结构
核心图3	Fig. 4 关键词共现网络图	RQ3	识别研究热点与技术主题之间的关系
核心表1	Table 1 Top 10 高被引文献表	RQ4	识别 milestone 候选论文和知识基础

表 4. 核心图表与研究问题的绑定关系。除上述三图一表外, 本文还使用方法流程、主题架构、共被引网络、里程碑路线图和挑战议程图补充解释。




Fig. 2. 年度发文增长与发展阶段图。数据源为 Lens.org 2020-2026 年清洗后 522 篇文献；柱形表示年度发文量，颜色表示探索、扩张和不完整年份等阶段。

Fig. 2 直接回答 RQ1。2020-2023 年总发文量较低，说明早期研究仍处在概念探索与场景试验阶段；2024 年开始显著上升，说明 AutoGen、CAMEL、MetaGPT、工具调用和 agentic workflow 等概念推动了研究对象的集中化；2025 年达到 344 篇，是样本期内最明显的扩张节点。

从 citation 指标看, 4,265 次总被引和 h 指数 31 表明该领域已经形成一批可被持续引用的基础文献。但篇均被引 8.17、被引中位数 1 和零被引文献较多也提示: 大量论文发表时间很近, 引用窗口尚短。因此, 本文把“快速扩张”与“技术成熟”区分开来, 前者由发文趋势支持, 后者仍需要更多真实场景和长期评估证据。

2026 年的 69 篇记录应作为不完整年份处理。如果把 2026 与 2025 直接比较, 会造成误读。本文在图注和正文中明确说明 2026 只是截至导出日期的部分样本, 这也是方法透明度的一部分。

年度趋势图的读法不是只看柱形高度，而是结合技术事件与引用窗口理解阶段变化。2023 年前的少量论文多具有探索性，2024 年后则出现框架化、场景化和评价化的研究增长。换言之，领域扩张不是单纯数量增加，而是研究对象从“LLM 能不能做任务”转向“多个 agent 如何协作完成复杂任务”。




Fig. 3. 作者合作网络图。节点表示作者，边表示重复共同署名关系；展示阈值为合作次数 ≥ 2 ，节点大小反映重复合作强度。

Fig. 3 回答 RQ2。过滤一次性合作后只剩 51 个节点和 48 条边，这说明虽然作者总数很大，但能够重复合作的稳定团队并不多。换言之，该领域仍处于快速形成阶段，很多团队围绕特定任务、框架或场景发表单篇论文，还没有形成高度集中的核心作者网络。

这种合作结构与 LLM 多智能体研究的跨学科属性有关。机器人、医学、软件工程、科学发现、HCI 和知识管理等方向都可能使用 LLM agent 概念，但它们的评价标准、数据集、实验环境和发表渠道不同，因此很难在短时间内形成统一共同体。

该图的节点表示作者，边表示重复共同署名关系。节点较大的作者不一定代表绝对学术权威，而是说明其在本样本中与他人形成了较多重复合作。边较稀疏意味着稳定合作关系尚未充分沉淀，这与“领域处于快速增长但共同体仍在形成”的判断一致。

Fig. 9 的机构与国家网络进一步说明空间分布具有多中心特征。该图不能被过度解释为“谁是绝对领导者”，因为数据库中的机构字段可能存在缺失和命名差异；它更适合作为补充证据，说明研究活动并非只集中在单一机构或单一国家。




Fig. 4. 关键词共现网络图。分析单元为文献关键词；同一篇文献内关键词去重，共现阈值 ≥ 2 ；节点大小表示关键词频次，边宽表示共现强度。




Fig. 5. 主题架构图。该图将关键词共现结果归纳为技术基础、协作架构、能力增强和应用治理四个层次，用于将计量结果转化为综述结构。

Fig. 4 和 Fig. 5 共同回答 RQ3。Fig. 4 保留更细的共现网络，用于观察关键词之间的实际连接；Fig. 5 则以综述写作

需要为导向，把关键词结构抽象为四层：技术基础、协作架构、能力增强和应用治理。

技术基础层的关键词包括 artificial intelligence、large language models、machine learning 和 natural language processing。这些词说明多智能体协作并不是孤立方法，而是建立在 LLM 能力、数据科学方法和 AI 系统工程之上。

协作架构层的关键词包括 multi-agent systems、AI agents、agentic AI、workflow、task planning 和 coordination。该层是本文主题的核心，因为它对应“多个 LLM agent 如何分工、交互、调用工具和校验结果”。

能力增强层包括 RAG、reinforcement learning、knowledge management 和 tool use 等概念。它们回答的是智能体如何获得外部知识、如何与环境交互、如何在任务失败后调整策略。这一层决定了系统能否从静态文本生成走向动态问题求解。

应用治理层包括 human-robot interaction、digital health、medicine、ethics、safety 和 human-AI collaboration。它提醒我们，LLM 多智能体系统一旦进入真实场景，就必须面对责任分配、风险控制、用户监督和制度约束。

关键词共现图也暴露出一个需要谨慎解释的问题：部分高频词如 ethics、marketing communication、media 等可能来自特定子领域的集中发文，不能简单等同于整个 LLM 多智能体领域的唯一热点。因此，本文把关键词网络与高被引论文、共被引网络和主题架构图结合起来解释，而不是单独依赖词频排名。

Core evidence chain

为增强图表证据与研究问题之间的对应关系，本文将 Fig. 2、Fig. 3、Fig. 4 和 Table 1 作为核心证据组，分别覆盖发展阶段、合作结构、研究热点和知识基础四个维度。四类证据共同指向一个基本判断：LLM 多智能体协作研究正在快速增长，但研究共同体仍较分散，主题结构已经分层，高影响文献集中在科学发现、机器人、人机协作和医疗等方向。

Fig. 2 的核心判断是“领域在 2024-2025 年进入快速扩张期”。其证据是年度发文量从 2023 年 19 篇上升到 2024 年 81 篇，再到 2025 年 344 篇。该变化说明该研究方向已从早期概念讨论转向更广泛的研究生产。不过，该图不能直接证明系统已经成熟，因为发文数量增加并不等同于工程可靠性已经解决。

Fig. 3 的核心判断是“研究参与者多，但稳定重复合作网络尚未充分形成”。其证据是作者总数达到 2,564，篇均作者数为 5.07，但过滤一次性合作后只剩 51 个节点和 48 条边。若研究活动高度集中，过滤后应出现更清晰的核心团簇；而当前网络仍较稀疏，说明大量论文可能来自不同团队围绕新兴议题的独立探索。

Fig. 4 的核心判断是“研究热点已经从单一 LLM 能力扩展为多层技术结构”。关键词网络中同时出现 large language models、multi-agent systems、RAG、reinforcement learning、human-robot interaction、digital health 和 ethics 等词，分别对应模型基础、协作机制、能力增强和应用治理。

Table 1 的核心判断是“知识基础具有明显的场景牵引特征”。Top 10 高被引论文中包含自驱动实验室、UAV 综述、剧本共写、人机协作、机器人任务规划、临床智能体和影像医学等方向，说明 LLM 多智能体研究的影响力不是只由单个通用框架支撑，而是通过多个应用场景扩散。

核心图表之间还存在互证关系。Fig. 2 说明研究增长足够明显，Fig. 3 说明增长背后的共同体结构仍在形成，Fig. 4 说明增长内容集中在哪些主题，Table 1 则说明哪些论文支撑这些主题。这样组织可以避免只看单一指标造成误读，例如只看发文量会高估成熟度，只看高被引论文会忽略新兴主题。

本文把图表解释分为三层。第一层是图注，说明数据源、分析单元、时间范围、工具和阈值；第二层是正文解释，说明图表回答哪个 RQ；第三层是讨论部分，把图表结果转化为更高层次的研究判断。通过这种结构，图表不再只是结果展示，而是参与论证的证据。

Parameter sensitivity and boundaries

参数阈值对文献计量结果有直接影响。以关键词共现为例，阈值为 1 时节点数达到 1,117，边数达到 19,681，虽然信息最完整，但图谱非常稠密，难以从视觉上识别稳定主题；阈值为 5 时只剩 25 个节点和 71 条边，图谱变得清晰，但会丢失 RAG、agentic AI、digital health 等新兴主题之间的联系。

因此，本文选择关键词共现阈值 ≥ 2 。这个阈值保留 233 个节点和 2,511 条边，在可读性和信息量之间比较平衡。阈值选择本身也是方法透明度的一部分，因为它直接影响图谱可读性和结论边界。

作者合作网络的阈值也需要解释。原始合作网络包含大量一次性共同署名，如果全部展示，会把几乎所有论文中的作者关系都画入图中，图像会呈现高度拥挤的结构。本文过滤一次性合作，是为了观察“稳定合作关系”，因此图中节点和边减少，并不代表其他作者不重要，而是代表本文的分析焦点不同。

时间窗口同样影响结论。2020-2023 窗口篇均被引较高，是因为早期文献有更长引用积累时间；2022-2025 窗口 h 指数与全窗口接近，说明核心影响力判断相对稳定；2026 年尚未完整，因此只作为补充趋势，不与完整年份直接比较。

4. Knowledge base and thematic review

R	Year	Cites	主题	代表性论文
1	2024	352	科学发现	Self-Driving Laboratories for Chemistry and Materials S...
2	2023	259	机器人协作	A Comprehensive Review of Recent Research Trends on Unm...
3	2023	173	人机协作	Co-Writing Screenplays and Theatre Scripts with Languag...
4	2025	136	科学发现	A review of large language models and autonomous agents...
5	2024	109	机器人协作	SMART-LLM: Smart Multi-Agent Robot Task Planning using ...
6	2024	108	医学智能体	Evaluating large language models as agents in the clinic.
7	2023	104	人机协作	Defining human-AI teaming the human-centered way: a sco...
8	2024	101	机器人协作	RoCo: Dialectic Multi-Robot Collaboration with Large La...
9	2024	100	机器人协作	Understanding Large-Language Model (LLM)-powered Human-...
10	2024	90	医学智能体	The impact of large language models on radiology: a gui...

Table 1. Top 10 高被引文献表。排序依据为 Lens.org Citing Works Count；该表用于识别 milestone 候选论文，并为主题综述提供知识基础。




Fig. 6. 参考文献共被引网络。节点表示被引参考文献，边表示共被引关系；节点大小表示样本内被引频次，边宽表示共被引强度，颜色表示主题簇。




Fig. 7. 里程碑论文路线图。图中将高被引文献放入科学发现、机器人协作、人机协作、医学智能体和工作流等叙事线索中，避免把 Table 1 解读为简单排名。

Table 1 和 Fig. 6 回答 RQ4。高被引论文提供 milestone 候选，共被引网络则说明这些论文是否在同一知识结构中共同引用。两者结合比单纯列出 Top 10 更可靠，因为 citation count 容易受发表时间、学科规模和综述类论文引用优势影响。

Top 10 中与 chemistry、materials science 和 self-driving laboratories 相关的论文被引较高，说明 LLM agent 在科学发现流程中的应用受到关注。这类研究通常把 agent 放入“文献检索—假设生成—实验设计—工具执行—报告撰写”的闭环中，具有较强的自动化想象力。

机器人与具身协作方向由 SMART-LLM、RoCo、UAV 综述和 human-robot interaction 论文体现。它们与纯文本任务不同，需要把自然语言计划转化为可执行动作，因此更强调约束、时序、环境反馈和错误恢复。

人机协作和医疗方向说明 LLM 多智能体系统不是简单替代人，而是重新分配人、模型、工具和制度之间的工作。临床智能体和影像医学论文尤其强调证据可追溯、专家审核和安全边界。

Fig. 6 的节点表示被共同引用的参考文献，边表示共被引关系。节点越大，说明该文献在样本中被引用次数越高；边越粗，说明两篇文献经常被同一论文共同引用。颜色聚类用于辅助识别知识基础，但不能被解释为严格学科分类。

Fig. 7 将 milestone 文献组织成路线图，可以帮助读者从“哪些论文被引多”进一步理解“这些论文分别支撑哪条技术叙事”。因此，本文在讨论中围绕科学发现、自动化 workflow、具身机器人、人机协作和垂直行业智能体展开，而不是按表格顺序机械复述。




Fig. 8. 引用网络图。节点为清洗后语料中的论文，边为可识别引用关系；该图用于补充观察知识传播路径，但受 references 字段覆盖率限制。




Fig. 9. 机构与国家分布网络图。该图用于辅助观察研究力量的空间分布；由于机构字段可能存在缺失或命名不一致，本文只作谨慎解释。

研究线索	核心思想	综述意义
AutoGen	多智能体对话 + 工具调用	任务分解、人工参与和工具协作
CAMEL	角色扮演式智能体社会	沟通协议、角色分工和多智能体模拟
MetaGPT	SOP 式软件团队	工程流程显性化和多角色协作
科学发现智能体	文献-假设-实验-报告闭环	自驱动实验室与科研自动化
机器人智能体	语言计划到可执行动作	具身协作、状态反馈和错误恢复
医疗智能体	临床证据与专家审核	高风险场景中的安全、责任和可追溯

表 5. 代表性框架与主题线索。该表把高被引论文、公开框架和关键词图谱转化为综述叙事。

Thematic synthesis

第一条主题线索是科学发现与自驱动实验室。Self-Driving Laboratories for Chemistry and Materials Science 与 chemistry autonomous agents 相关综述被引较高，说明 LLM 多智能体系统已经进入科研自动化讨论。其核心逻辑是让不同 agent 分别承担文献检索、假设生成、实验方案设计、数据解释和报告撰写等角色，从而把科研流程显性化。

这一方向的优势在于能处理跨文献、跨工具和跨步骤的信息整合任务。传统科研自动化系统往往依赖固定流程，而 LLM agent 可以根据目标动态规划步骤，并通过工具调用连接数据库、计算程序或实验平台。但它也带来风险：如果

假设生成缺少领域约束，系统可能产生看似合理但无法实验验证的建议；如果实验执行缺少人工审核，则可能引发安全和伦理问题。

第二条主题线索是机器人和具身协作。SMART-LLM、RoCo 以及 UAV 综述说明，LLM 多智能体研究正在从文本世界进入物理世界。在这类任务中，agent 不仅要生成语言答案，还要将任务分解为动作序列，处理空间约束、时间顺序、多机器人通信和环境反馈。

机器人方向对多智能体系统提出了比文本任务更严格的要求。文本任务中的错误可以通过重新生成或人工编辑修正，但物理动作中的错误可能导致设备损坏或安全风险。因此，机器人智能体需要更强的计划验证、状态监控、权限边界和失败恢复机制。这个方向也说明，多智能体协作的关键不只是“多个角色讨论”，而是把讨论结果转化为可执行、可验证的行动。

第三条主题线索是人机协作与创造性工作。Co-Writing Screenplays and Theatre Scripts with Language Models 以及 human-AI teaming 相关论文表明，LLM agent 不只是自动化工具，也可以作为人类创作和决策过程中的协作者。在剧本写作、设计、教育和知识工作中，多智能体系统可以模拟不同角色、提供多视角反馈、帮助用户比较方案。

但是，人机协作方向不能只强调“生成更多想法”。真正重要的是协作关系如何被设计：人类何时介入，agent 的建议如何被标注，错误如何被纠正，不同 agent 的意见冲突如何呈现给用户。如果这些机制缺失，多智能体系统可能放大幻觉、制造过度自信或让用户误以为结果已经经过充分验证。

第四条主题线索是医疗与高风险垂直应用。Evaluating large language models as agents in the clinic 和 radiology 相关论文说明，医学领域开始关注 LLM agent 的辅助潜力。这类系统可以支持病例信息整理、指南检索、影像报告解释和临床决策辅助，但其输出必须受到更严格的证据约束。

医疗场景尤其强调责任边界。多智能体系统可能包含检索 agent、推理 agent、报告 agent 和审查 agent，但最终责任不能简单转移给模型。每一步都需要可追溯证据、专家审核和日志记录。由此可见，高风险场景是检验多智能体系统是否具备可审计性的重要场域。

第五条主题线索是工程化 workflow。AutoGen、CAMEL 和 MetaGPT 等框架虽然不一定全部出现在 Top 10 高被引表中，但它们构成了理解 LLM 多智能体系统的重要背景。它们的共同点是把复杂任务拆解为角色、消息、工具和流程，使原本隐性的协作过程变得可观察。

从综述角度看，工程化 workflow 是连接其他场景的底层方法。无论是科学发现、机器人、医疗还是人机协作，都需要定义 agent 角色、输入输出格式、工具调用权限、记忆机制和失败处理策略。未来研究若只比较最终任务成功率，而不记录协作过程，就很难判断系统改进来自模型能力、提示词设计、工具质量还是多智能体结构本身。

综合这些主题线索可以看到，LLM 多智能体协作研究的核心问题已经从“LLM 能不能完成任务”转向“多个 LLM agent 如何在有约束的环境中可靠协作”。因此，本文没有

停留在图谱描述层面，而是进一步把高被引论文和关键词结构转化为几条具体研究主线，以解释该领域为何在这些方向上形成影响力。

Interpretive boundaries of supporting figures

Fig. 1 方法流程图交代研究如何从检索进入综述，而不是展示研究结果本身。它把 Lens.org 检索、原始数据导出、去重清洗、指标计算、网络构建、主题归纳和论文写作放入同一流程，说明本文的结论来自一组可复核步骤。

Fig. 5 主题架构图是对 Fig. 4 的解释性重绘。关键词共现网络保留细节，但节点和边较多，读者不容易直接看到综述结构；主题架构图则把复杂网络压缩为四个层次，使论文后续可以围绕“技术基础—协作架构—能力增强—应用治理”展开。

Fig. 6 共被引网络用于补充 Table 1 的不足。Table 1 只显示单篇论文的被引次数，而共被引网络能显示论文之间是否经常被共同引用。如果两篇文献经常被共同引用，说明它们可能在读者心中共同构成某一知识基础或问题框架。

Fig. 7 里程碑路线图的作用是把文献名单转化为叙事线索。高被引文献表回答“哪些论文重要”，路线图回答“这些论文为什么重要、分别支持什么方向”。因此它更接近综述写作中的 thematic synthesis，而不是纯计量图。

Fig. 8 引用网络和 Fig. 9 机构国家网络属于辅助图。引用网络帮助观察知识传播路径，但由于 references 覆盖率为 81.99%，不能当作完整引用宇宙；机构国家网络帮助观察空间分布，但机构命名差异可能影响精确排名。本文把它们用于增强解释，而不是作为强结论来源。

Fig. 10 基于前文的增长趋势、合作结构、主题分层和高风险应用讨论，总结出评价、解释性、场景验证和治理四类未来议题。领域越扩张，越需要评价标准；系统越复杂，越需要可解释日志；应用越贴近真实场景，越需要安全治理。

5. Discussion and future agenda

第一条讨论主线是自动化 workflows。AutoGen 和 MetaGPT 等框架的价值不只在“多个模型聊天”，而在于把复杂任务拆分为可观察、可干预、可复盘的流程。因此，本项目将检索式、参数设置和图表输出保存在 GitHub 中，以便复核从数据处理到论文结论的完整过程。

第二条主线是科学发现。高被引化学和材料科学论文表明，LLM agent 可以参与科研流程的多个环节，但它们不能替代实验验证。最合理的定位是增强研究者的信息处理、假设生成和实验设计能力，同时保留专家审查、实验安全和数据可追溯。

第三条主线是具身智能和机器人协作。机器人任务规划对 LLM multi-agent systems 提出了更高要求：语言计划必须可执行，多个机器人之间需要共享状态，环境变化要被反馈到规划中，失败动作也要有恢复策略。这使该方向成为检验多智能体系统可靠性的关键场景。

第四条主线是人机协作与垂直行业应用。在医疗、教育、软件工程和业务流程中，LLM agent 的输出会影响真实决策，因此需要权限控制、审计日志、责任边界和人类最终确认。多智能体结构越复杂，越需要清楚记录每个 agent 的输入、输出和工具调用。

从方法论上看，bibliometric review 的优势是能够提供宏观结构，但它不能替代深度内容阅读。本文把计量结果当作组织综述的入口，再通过代表性论文和公开框架进行解释，尽量避免把网络图误读为因果关系。

从工程化角度看，未来更重要的问题不是“能否再增加几个 agent”，而是如何定义 agent 的角色、权限、记忆、通信协议和失败处理。没有这些边界，多智能体系统很容易变成不可控的长链调用，输出看似丰富但难以验证。

从评价角度看，未来基准应同时关注最终结果质量、协作过程质量、成本、稳定性和安全性。例如，同一任务中 agent 是否重复劳动、是否产生冲突、冲突是否被解决、工具调用是否越权、外部证据是否可追溯，都应该成为评价指标。

换言之，未来研究不仅要展示多智能体系统能够完成复杂任务，还要说明任务分解是否合理、工具调用是否可追溯、错误能否定位以及系统成本是否可接受。只有在这些问题得到处理后，LLM 多智能体系统才可能从演示型系统走向可评价、可解释、可审计和可落地的智能基础设施。




Fig. 10. 挑战与未来研究议程图。该图将 bibliometric signals 转化为评价、可解释性、真实场景验证和安全治理四类未来研究方向。

本文存在若干局限。第一，数据只来自 Lens.org，虽然字段丰富且便于复现，但不同数据库在收录范围、引用数据和会议论文覆盖上存在差异。若使用 Web of Science、Scopus、OpenAlex 或 Google Scholar，结果可能有所变化。

第二，检索式虽然兼顾 LLM 和协作方法，但仍可能遗漏使用不同术语的论文，例如 autonomous workflow、agent society、planner-executor architecture 或 tool-augmented reasoning。相反，也可能纳入部分与 LLM 多智能体协作关系较弱的广义人机协作或机器人综述论文。

第三，引用分析存在时间滞后。2024-2026 年新论文即使质量较高，也可能因为发表时间短而被引较少；早期综述类论文则天然拥有更长引用窗口。因此，本文把 Top 10 视为 milestone 候选，而不是绝对质量排名。

第四，共被引和关键词共现网络依赖阈值设置。阈值过低会造成噪声，阈值过高会损失新兴主题。本文通过敏感性分析说明阈值选择理由，但网络图仍应被理解为“辅助解释工具”，不是完整事实本身。

6. Reproducibility and AI-use statement

可复现性是本文与一般课堂综述的主要区别。普通综述往往只在方法部分描述检索过程，而本项目把检索式、清洗记录、字段字典、参数说明、分析脚本、图表输出和最终论文统一放在 GitHub 目录中，使读者可以沿着同一条路径检查结论。

在数据层面，原始记录、清洗后记录和筛选说明分别保存，便于核对 542 到 522 的样本变化。在方法层面，query.yaml 记录检索词组，params.md 记录阈值选择理由，reports 目录保存 M1-M3 阶段性分析。这样的结构可以降低“只给结果不给过程”的问题。

在图表层面，本文将每张图与 RQ 绑定。年度趋势图回答增长阶段，作者网络回答合作结构，关键词图回答主题层次，高被引表和共被引网络回答知识基础，挑战路线图回答未来研究议程。

AI 使用方面，本文允许 AI 辅助做结构整理、语言润色、排版检查和图表解释逻辑核对，但不允许 AI 编造数据、替代人工筛选、伪造引用或生成无法追溯的结论。所有数字均来自项目数据或输出文件，图表解释也围绕可复核指标展开。

核对项	项目材料
数据来源	Lens.org Scholarly Works; data/raw 与 data/processed 保留记录
检索与筛选	config/query.yaml, data/screening_records.csv, reports/query_changelog.md
参数透明	params.md 记录时间窗、阈值、Top N、网络过滤规则
图表说明	核心三图一表均绑定 RQ，辅助图表用于补充主题解释
复现入口	run_pipeline.py 与 requirements.txt
AI 声明	docs/ai_usage.md 与正文声明共同说明使用边界

表 6. 课程论文可复核材料清单。该表说明论文结论能够追溯到 GitHub 项目中的数据、参数和输出。

7. Conclusions

本文基于 522 篇 Lens.org 文献，对 LLM 多智能体协作研究进行了文献计量型课程综述。研究发现，该领域在 2024-2025 年进入快速扩张期，主题结构已从 LLM/AI 技术底座延伸到智能体协作架构、RAG/RL 能力增强、垂直应用和安全治理。作者合作网络显示研究共同体仍较分散；高被引表、共被引网络和里程碑路线图进一步揭示了科学发现、机器人任务规划、人机协作和医疗智能体等知识基础。

因而，本文的主要价值不只在总结主题，也在于保留了从数据获取、参数设定到图表解释的可复核路径。未来研究应从演示型系统走向可评价、可解释、可审计和可落地的智能基础设施，并在具体场景中持续检验多智能体协作的可靠性与责任边界。

References

[1] Guo T. et al. Large Language Model based Multi-Agents: A Survey of Progress and Challenges. arXiv:2402.01680, 2024.

[2] Wu Q. et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation Framework. arXiv:2308.08155, 2023.

[3] Li G. et al. CAMEL: Communicative Agents for Mind Exploration of Large Scale Language Model Society. NeurIPS, 2023.

[4] Hong S. et al. MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework. arXiv:2308.00352, 2023.

[5] Tom G. et al. Self-Driving Laboratories for Chemistry and Materials Science. Chemical Reviews, 2024. DOI: 10.1021/acs.chemrev.4c00055.

[6] Telli K. et al. A Comprehensive Review of Recent Research Trends on Unmanned Aerial Vehicles (UAVs). Systems, 2023. DOI: 10.3390/systems11080400.

[7] Mirowski P. et al. Co-Writing Screenplays and Theatre Scripts with Language Models: Evaluation by Industry Professionals. CHI, 2023. DOI: 10.1145/3544548.3581225.

[8] Ramos M. C. et al. A review of large language models and autonomous agents in chemistry. Chemical Science, 2025. DOI: 10.1039/d4sc03921a.

[9] Kannan S. S. et al. SMART-LLM: Smart Multi-Agent Robot Task Planning using Large Language Models. IROS, 2024. DOI: 10.1109/iros58592.2024.10802322.

[10] Mehandru N. et al. Evaluating large language models as agents in the clinic. NPJ Digital Medicine, 2024. DOI: 10.1038/s41746-024-01083-y.

[11] Berretta S. et al. Defining human-AI teaming the human-centered way: a scoping review and network analysis. Frontiers in Artificial Intelligence, 2023. DOI: 10.3389/frai.2023.1250725.

[12] Mandi Z. et al. RoCo: Dialectic Multi-Robot Collaboration with Large Language Models. ICRA, 2024. DOI: 10.1109/icra57147.2024.10610855.

[13] Kim C. Y. et al. Understanding Large-Language Model (LLM)-powered Human-Robot Interaction. HRI, 2024. DOI: 10.1145/3610977.3634966.

[14] Nakaura T. et al. The impact of large language models on radiology: a guide for radiologists on the latest innovations in AI. Japanese Journal of Radiology, 2024. DOI: 10.1007/s11604-024-01552-0.

[15] 课程 GitHub 项目材料: config/query.yaml, params.md, data/processed/cleaned_data.csv, outputs/figures/, outputs/review_figures/, outputs/tables/.